

Análisis Exploratorio de Datos

El Análisis Exploratorio de Datos se realizó con el objetivo de comprender la estructura del conjunto de datos, identificar problemas de calidad en la información y definir las estrategias de limpieza necesarias antes del entrenamiento de los modelos de aprendizaje no supervisado. Durante este proceso se evaluaron los tipos de datos, valores faltantes, registros duplicados, distribuciones estadísticas, presencia de valores atípicos, correlaciones entre variables y validación de rangos permitidos para cada atributo.

Freelancers

Información general del data set

El conjunto de datos de freelancers está compuesto por 1,590 registros y 11 variables, que incluyen atributos numéricos y categóricos relacionados con la actividad y desempeño de cada freelancer.

Durante esta etapa se identificó que varias columnas numéricas fueron cargadas como tipo object, debido a la presencia de valores no numéricos como "sin dato", "nd" y "?". Esta situación impide realizar operaciones estadísticas directamente, por lo que fue necesario convertir dichas columnas al tipo numérico utilizando **pd.to_numeric(errors="coerce")**, transformando estos valores inválidos en valores nulos para tratarlos luego.

```
In [4]: 1 df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1590 entries, 0 to 1589
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   freelancer_id         1590 non-null   object  
1   proyectos_completados 1590 non-null   object  
2   ingresos_totales      1590 non-null   float64 
3   tarifa_hora_promedio  1551 non-null   object  
4   años_experiencia      1558 non-null   float64 
5   tiempo_respuesta_horas 1561 non-null   float64 
6   tasa_finalizacion     1537 non-null   float64 
7   calificacion_promedio  1550 non-null   object  
8   categoria_principal   1590 non-null   object  
9   clientes_recurrentes  1590 non-null   int64   
10  horas_trabajadas_mes   1590 non-null   float64 
dtypes: float64(5), int64(1), object(5)
memory usage: 136.8+ KB
```

```
In [3]: 1 print("Filas:",df.shape[0])
        2
        3 print("Columnas:",df.shape[1])
```

```
Filas: 1590
Columnas: 11
```

Valores faltantes

Se identificaron pocos valores faltantes en las variables numéricas. Ninguna columna supera el 5 % de datos ausentes, siendo la variable tasa_finalizacion la que presenta el mayor porcentaje (3.33 %).

Ya que no hay muchos valores faltantes, eliminar esos datos sería una pérdida innecesaria de registros. Por lo tanto, decidimos conservar todos los registros e imputar los valores faltantes. Para decidir el método de imputación, se realizó un análisis de la distribución de cada variable utilizando el coeficiente de asimetría.

```
In [6]: 1 df.isnull().sum()
```

```
freelancer_id      0
proyectos_completados  0
ingresos_totales   0
tarifa_hora_promedio 39
anios_experiencia  32
tiempo_respuesta_horas 29
tasa_finalizacion  53
calificacion_promedio 40
categoria_principal  0
clientes_recurrentes  0
horas_trabajadas_mes  0
dtype: int64
```

```
In [7]: 1 (df.isnull().sum()/len(df))*100
```

freelancer_id	0.000000
proyectos_completados	0.000000
ingresos_totales	0.000000
tarifa_hora_promedio	2.452830
anios_experiencia	2.012579
tiempo_respuesta_horas	1.823899
tasa_finalizacion	3.333333
calificacion_promedio	2.515723
categoria_principal	0.000000
clientes_recurrentes	0.000000
horas_trabajadas_mes	0.000000
dtype:	float64

Registros duplicados

Se detectaron 90 registros duplicados dentro del conjunto de datos. Ya que es información repetida y pueden introducir sesgos durante el proceso de agrupamiento, decidimos eliminarlos.

```
In [8]: 1 df.duplicated().sum()
```

90

Conversión de tipos de datos

Durante la exploración se observó que las variables proyectos_completados, tarifa_hora_promedio y calificacion_promedio fueron interpretadas como texto debido a la presencia de valores no válidos. Estos valores fueron convertidos a valores nulos mediante la función `pd.to_numeric(errors="coerce")`, para poder aplicar las estrategias de imputación.

```
In [9]: 1 df.dtypes
```

freelancer_id	object
proyectos_completados	object
ingresos_totales	float64
tarifa_hora_promedio	object
anios_experiencia	float64
tiempo_respuesta_horas	float64
tasa_finalizacion	float64
calificacion_promedio	object
categoria_principal	object
clientes_recurrentes	int64
horas_trabajadas_mes	float64
dtype:	object


```
In [21]: 1 df.dtypes







freelancer_id      object
proyectos_completados  float64
ingresos_totales    float64
tarifa_hora_promedio  float64
anios_experiencia    float64
tiempo_respuesta_horas  float64
tasa_finalizacion    float64
calificacion_promedio  float64
categoria_principal   object
clientes_recurrentes  int64
horas_trabajadas_mes  float64
dtype: object
```

Distribución de las variables

Debido al coeficiente de asimetría, se pudo evaluar la forma de distribución de cada variable numérica. La mayoría de variables presentan distribuciones asimétricas, destacando años de experiencia, tiempo de respuesta, tarifa por hora e ingresos totales, cuyos coeficientes de asimetría son superiores a 0.5 en valor absoluto.

Únicamente calificación promedio y horas trabajadas por mes presentan distribuciones cercanas a la simetría. Por lo tanto, decidimos utilizar la mediana como método de imputación para las variables numéricas, ya que es menos sensible a valores extremos que la media.









```
1 df[numerics].skew()
```

```
proyectos_completados    1.111398
ingresos_totales          0.897336
tarifa_hora_promedio      1.383146
anios_experiencia         5.654916
tiempo_respuesta_horas    1.789893
tasa_finalizacion         -1.720288
calificacion_promedio     -0.281823
clientes_recurrentes      1.115363
horas_trabajadas_mes      0.235224
dtype: float64
```

Valores atípicos

El análisis mediante el método del rango intercuartílico (IQR) permitió identificar posibles valores atípicos en varias variables. sin embargo, estos valores corresponden a freelancers con características particulares, como ingresos elevados, alta experiencia o tiempos de respuesta extremos, por lo que representan casos reales y no necesariamente errores de captura. Por lo tanto, decidimos conservar dichos registros y solo corregir los valores que violan restricciones lógicas definidas por el dominio del problema.






```
1 df[numerics].skew()
```

```
proyectos_completados    1.111398
ingresos_totales          0.897336
tarifa_hora_promedio      1.383146
anios_experiencia         5.654916
tiempo_respuesta_horas    1.789893
tasa_finalizacion         -1.720288
calificacion_promedio     -0.281823
clientes_recurrentes      1.115363
horas_trabajadas_mes      0.235224
dtype: float64
```


Correlación

La matriz de correlación muestra relaciones importantes entre algunas variables del conjunto de datos. Se observa una alta correlación positiva entre ingresos_totales y tarifa_hora_promedio, así como entre proyectos_completados, clientes_recurrentes y horas_trabajadas_mes, lo que resulta consistente con el comportamiento esperado de la plataforma. No encontramos correlaciones perfectas, por lo tanto no hay necesidad de eliminar variables.



Variables categóricas

La variable categoria_principal presenta cinco categorías principales de servicio, siendo Desarrollo de Software la de mayor frecuencia. No se identificaron categorías inconsistentes ni registros vacíos, por lo que solo se estableció que en caso de presentarse valores faltantes durante la limpieza, estos serían imputados utilizando la moda de la variable.



Validación de reglas de dominio

Finalmente, verificamos que los datos respetaran las restricciones propias del dominio del problema. No se encontraron ingresos ni años de experiencia negativos. Sin embargo, se identificaron 27 registros con tasas de finalización fuera del rango permitido de 0 a 100 %, así como 23 registros con calificaciones fuera del intervalo de 0 a 5. Estos valores fueron considerados inconsistencias de captura y decidimos reemplazarlos utilizando la mediana correspondiente a cada variable.

```
1 (df["ingresos_totales"]<0).sum()
0

1 (df["anios_experiencia"]<0).sum()
0

1 ((df["tasa_finalizacion"]<0)|(df["tasa_finalizacion"]>100)).sum()
27

1 ((df["calificacion_promedio"]<0)|(df["calificacion_promedio"]>5)).sum()
23
```

Reseñas

Información general del data se

El conjunto de datos de reseñas está compuesto por 5,250 registros y 5 variables, todas de tipo object. Estas variables almacenan el identificador de la reseña, el identificador del freelancer, el texto de la reseña, la fecha en que fue realizada y la categoría del servicio asociado.

Durante esta etapa se verificó la estructura general del conjunto de datos y se confirmó que no existían problemas relacionados con identificadores faltantes o columnas ausentes, permitiendo continuar con el análisis de calidad de los datos.

```
1 print(df.shape)
2
3 df.info()

(5250, 5)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5250 entries, 0 to 5249
Data columns (total 5 columns):
#   Column          Non-Null Count  Dtype
---  -
0   reseña_id       5250 non-null   object
1   freelancer_id   5250 non-null   object
2   texto_reseña    5143 non-null   object
3   fecha_reseña    4989 non-null   object
4   categoria_servicio 5094 non-null   object
dtypes: object(5)
memory usage: 205.2+ KB
```

Valores faltantes

Se realizó un análisis de valores faltantes para identificar posibles problemas de calidad de los datos antes del entrenamiento del modelo.

Los resultados muestran que:

- texto_reseña: 107 valores nulos (2.04 %)
- fecha_reseña: 261 valores nulos (4.97 %)
- categoria_servicio: 156 valores nulos (2.97 %)

Los identificadores de reseña y freelancer no presentan valores faltantes.

Debido a que el texto de la reseña constituye la principal fuente de información para el proceso de segmentación, las reseñas sin texto fueron eliminadas del conjunto de datos, ya que no es posible reconstruir dicha información mediante técnicas de imputación.

En el caso de la variable categoria_servicio, los valores faltantes fueron imputados utilizando la **moda**, debido a que se trata de una variable categórica y el porcentaje de datos faltantes es reducido.

Las fechas inválidas o faltantes fueron eliminadas, ya que no existe un criterio confiable para estimarlas y representan menos del 5 % del conjunto de datos.

```
1 nulos = pd.DataFrame({
2     "Cantidad": df.isnull().sum(),
3     "Porcentaje": (df.isnull().sum()/len(df))*100
4 })
5
6 nulos
```

	Cantidad	Porcentaje
reseña_id	0	0.000000
freelancer_id	0	0.000000
texto_reseña	107	2.038095
fecha_reseña	261	4.971429
categoria_servicio	156	2.971429

Registros duplicados



Se identificaron **250 registros duplicados** dentro del conjunto de datos. Debido a que representan información repetida y pueden afectar la distribución de los segmentos obtenidos mediante clustering, dichos registros fueron eliminados antes del entrenamiento del modelo.

```
1 duplicados = df.duplicated().sum()
2 print("Duplicados:", duplicados)
```

Duplicados: 250


Longitud de las reseñas

Se calculó la longitud de cada reseña utilizando el número de palabras presentes en el texto. La longitud promedio fue de 25.03 palabras, con un rango entre 1 y 49 palabras. Esta variable será utilizada posteriormente durante el análisis descriptivo de los segmentos obtenidos.



Categorías de servicio

La categoría con mayor frecuencia corresponde a Desarrollo de Software, seguida por Diseño Gráfico y Marketing Digital. Debido a que únicamente existen cinco categorías y el porcentaje de valores faltantes es bajo, se decidió imputar los registros sin categoría utilizando la moda de la variable



Fechas de las reseñas

Se identificaron 261 fechas inválidas, las cuales fueron convertidas a valores nulos mediante `pd.to_datetime(errors="coerce")`. Debido a que no es posible inferir correctamente la fecha original de cada reseña, estos registros fueron eliminados durante el proceso de limpieza.

```
1 fechas.dt.year.value_counts().sort_index()
```

```
fecha_reseña
2011.0      30
2012.0      43
2013.0      16
2014.0       8
2020.0     635
2021.0    1068
2022.0     999
2023.0    1056
2024.0    1034
2025.0      56
2026.0      44
Name: count, dtype: int64
```